2026 IT 시스템종합설계

SNS 혐오 · 차별 발언 자동 탐지 및 등급 분류 시스템

ANN · CNN · RNN 기반 멀티태스크 분류 모델 비교

데이터	K-HATERS · 192,158 건
문제	혐오 카테고리 (4 종) + 심각도 (4 단계) 동시 분류
모델	ANN / CNN / RNN 비교 + 앙상블 + KLUE-RoBERTa

지도교수 : 임종태 교수님 | 소속 : 홍익대학교 산업데이터공학과 C221087 이승훈



RESEARCH BACKGROUND & MOTIVATION

왜 혐오 표현 자동 탐지인가 ?

SNS 내 혐오 표현의 급격한 확산

- 온라인 커뮤니티 · SNS 플랫폼에서 차별 발언이 빠르게 증가
- 전파 속도가 매우 빨라 사회적 갈등을 심화

å 자동화 탐지의 필요성

- 사람이 일일이 검수하기엔 데이터 양이 너무 많음
- 객관적 · 일관된 기준의 딥러닝 기반 자동화 필요

기존 연구의 한계

- 대부분 ' 혐오 / 정상 ' 이진 판별에 머무름
- 혐오의 종류 · 강도 (심각도) 를 고려하지 못함

본 연구의 차별점 — 멀티태스크

- 혐오 종류 (Category) + 강도 (Severity) 를 동시 판별
- 세분화된 라벨링으로 정교한 콘텐츠 모니터링 지원

입력 *" 여자가 무슨 운전이야 "* → **카테고리** 성별 혐오 · **심각도** 혐오 (강)

출처 · 문제 설정은 K-HATERS 데이터셋의 라벨 체계 기반

DATASET CHARACTERISTICS & DISTRIBUTION

학습 데이터 — K-HATERS

1 데이터 규모 및 출처

한국어 뉴스 댓글 기반 , 총 192,158 건의 대규모 코퍼스

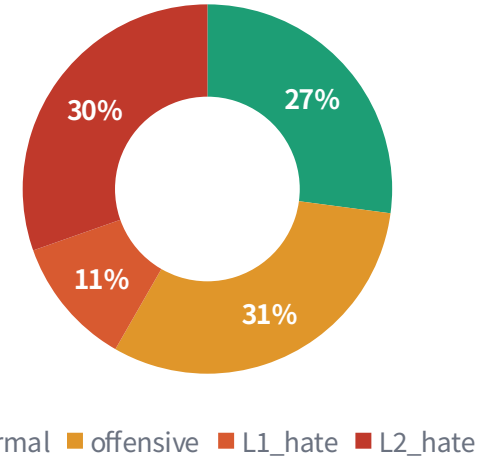
2 고품질 라벨링

숙련된 작업자가 직접 검수한 신뢰도 높은 데이터

3 멀티태스크 속성

심각도 4 단계 + 혐오 카테고리를 동시 보유한 유일한 한국어 데이터셋

K-HATERS 심각도 분포 (Severity Distribution)



등급 (Severity)	비율	특징
normal (정상)	27.1%	일반적인 일상 대화 · 정보성 댓글
offensive (공격적)	31.2%	비속어 포함 또는 무례한 표현
L1_hate (약한 혐오)	11.3%	특정 집단에 대한 우회적 차별 표현
L2_hate (강한 혐오)	30.4%	노골적인 혐오 · 폭력적 발언

출처 · K-HATERS, Park et al., EMNLP 2023 Findings

PREPROCESSING & LABEL DESIGN

데이터 전처리와 멀티태스크 라벨 구성

전처리 (Preprocessing)

NFC 정규화 | #@ 익명 # 제거 | URL 제거 | @ 멘션 제거

<HTML> 제거 | 자모 반복 축소 | 공백 정규화

BEFORE

ㅋㅋㅋㅋㅋ #@ 닉네임 # 진짜 https://t.co/a 짜증나
 @user

↓

AFTER

ㅋㅋ 진짜 짜증나

라벨 설계 — 핵심 의사결정

1 카테고리 통합

9 종 → 4 종으로 통합 (성별 / 인종 · 출신 / 연령 / 기타)

2 카테고리 = 이진 분류

한 문장에 여러 혐오가 동시에 존재할 수 있음 (multi-label)

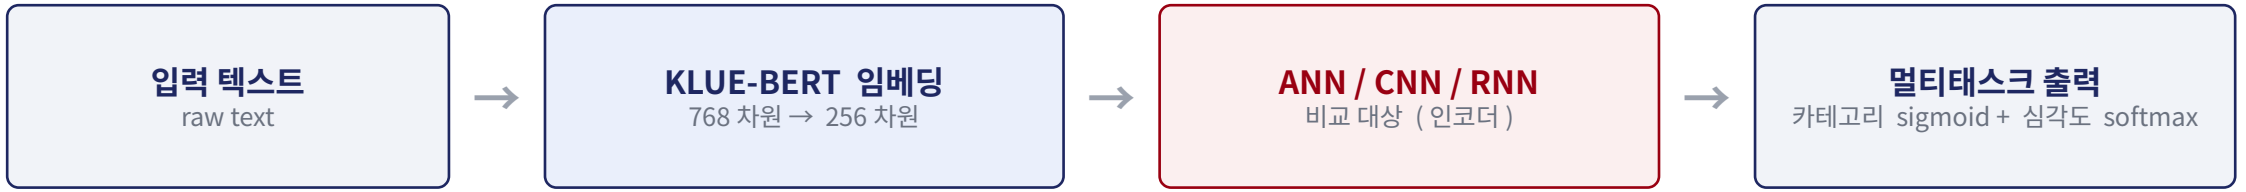
3 심각도 = 4 단계 분류

softmax 기반 단일 다중 클래스 분류

※ " 여자 노인이 운전하면 " → 성별 · 연령 혐오 동시 → 단일 분류 불가 → 멀티태스크로 전환

MODEL ARCHITECTURE

세 가지 신경망 구조 (ANN / CNN / RNN)



ANN

핵심 구조

Mean + Max Pooling → MLP

특징

단순한 구조 , 단어 순서 무시

TextCNN

핵심 구조

Conv1D (커널 2,3,4,5) + BatchNorm

특징

지역적 n-gram 패턴 포착

BiLSTM(RNN)

핵심 구조

양방향 LSTM + Self-Attention

특징

단어 순서 · 문맥 반영

출처 · TextCNN — Kim, EMNLP 2014 / 임베딩 — KLUE, Park et al. 2021

TRAINING CONFIGURATION

학습 환경 및 하이퍼파라미터

1 데이터 분할

- 학습 80% / 검증 10% / 평가 10%
- 심각도 기준 층화추출

2 손실 함수

- 카테고리 BCEWithLogitsLoss (pos_weight)
- 심각도 CrossEntropy (class weight + label smoothing)

3 최적화

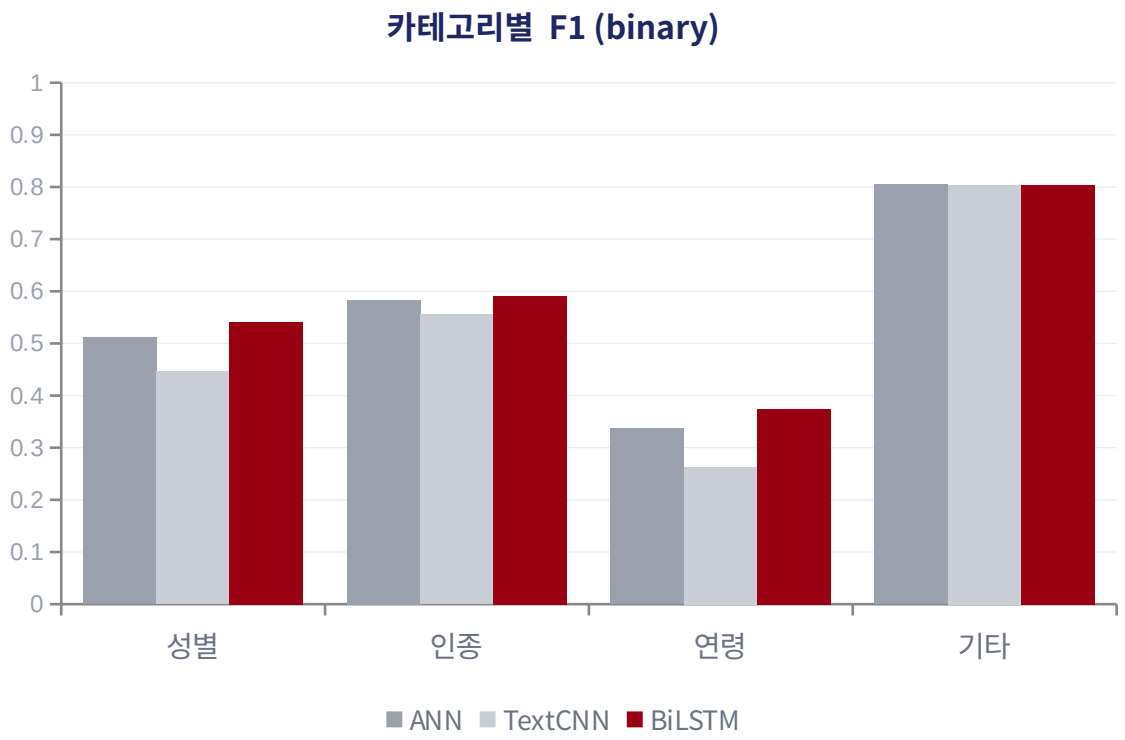
- AdamW · Cosine + Warmup
- 임베딩 lr 1e-5 / 그 외 1e-4

4 학습 스케줄

- Epochs 8 · Early Stopping (patience 3)
- Apple Silicon (MPS) 환경

EXPERIMENT RESULT ① — MODEL COMPARISON

실험 결과 — ANN vs CNN vs RNN



모델	카테고리 평균	심각도	종합 F1
ANN	0.559	0.563	0.561
TextCNN	0.517	0.566	0.541
BiLSTM · 최고 성능	**0.577**	**0.565**	**0.571**

핵심 발견

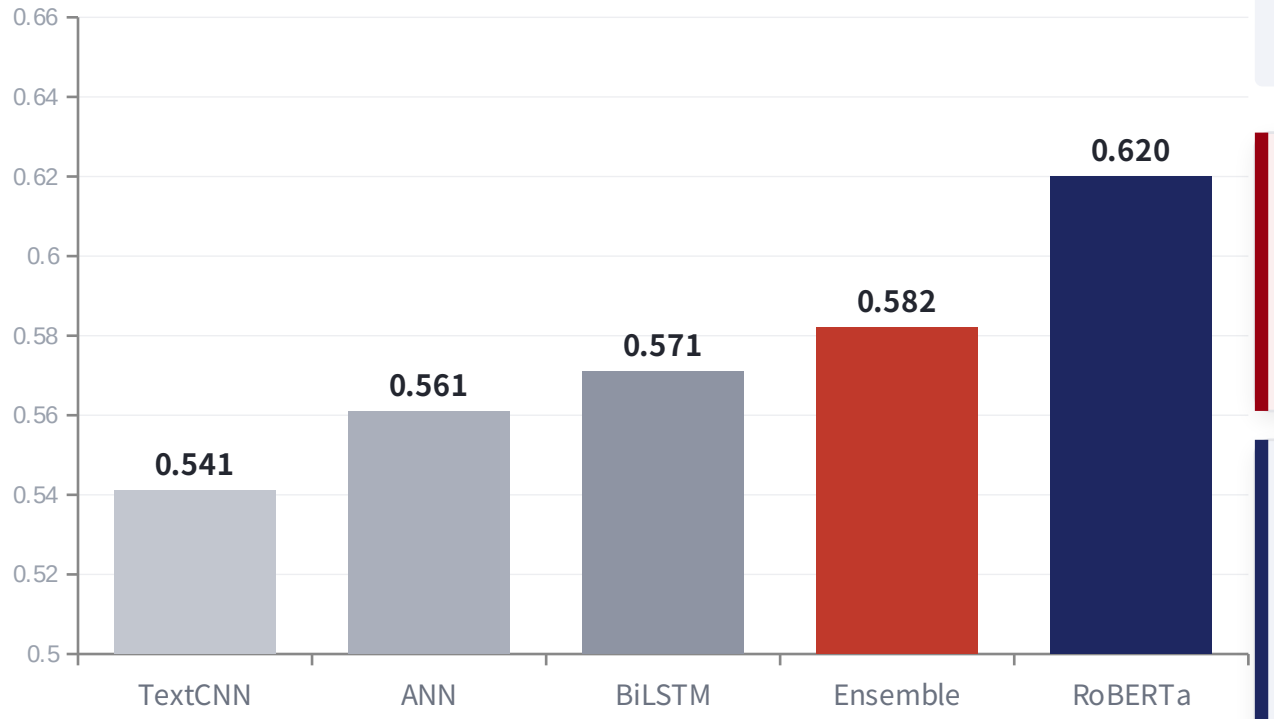
- 성능 순위 : BiLSTM > ANN > TextCNN
- 시퀀스 모델 (BiLSTM) 이 한국어 문맥 파악에 가장 유리
- 전 모델이 ' 기타 '(~0.80) 는 잘 , ' 연령 '(0.26~0.37) 은 어려워함

출처 · 평가지표 Macro F1-score (Test set)

EXPERIMENT RESULT ② — IMPROVEMENT & BENCHMARK

성능 발전 — 앙상블 & 사전학습 비교

종합 F1 — 단일 → 앙상블 → 사전학습



앙상블 가중치 (Validation F1 기준)

ANN	TextCNN	BiLSTM
0.334	0.331	0.336

① 앙상블 효과

+1.05%p 0.571 → 0.582

BiLSTM 단일 최고 대비 , 4 개 카테고리 · 심각도 전 항목에서 일관되게 향상

② 사전학습 모델 (KLUE-RoBERTa) 격차

+3.8%p 0.582 → 0.620

격차가 압도적이지 않음 → 직접 구현한 모델 + 앙상블도 충분히 경쟁력 있음

출처 · Weighted Voting Ensemble / KLUE-RoBERTa, Park et al. 2021

SYSTEM IMPLEMENTATION — LIVE WEB DEMO

실시간 탐지 시스템 구현

1 **Streamlit 웹 인터페이스**

브라우저에서 바로 동작하는 실시간 탐지 UI

2 **즉시 판별**

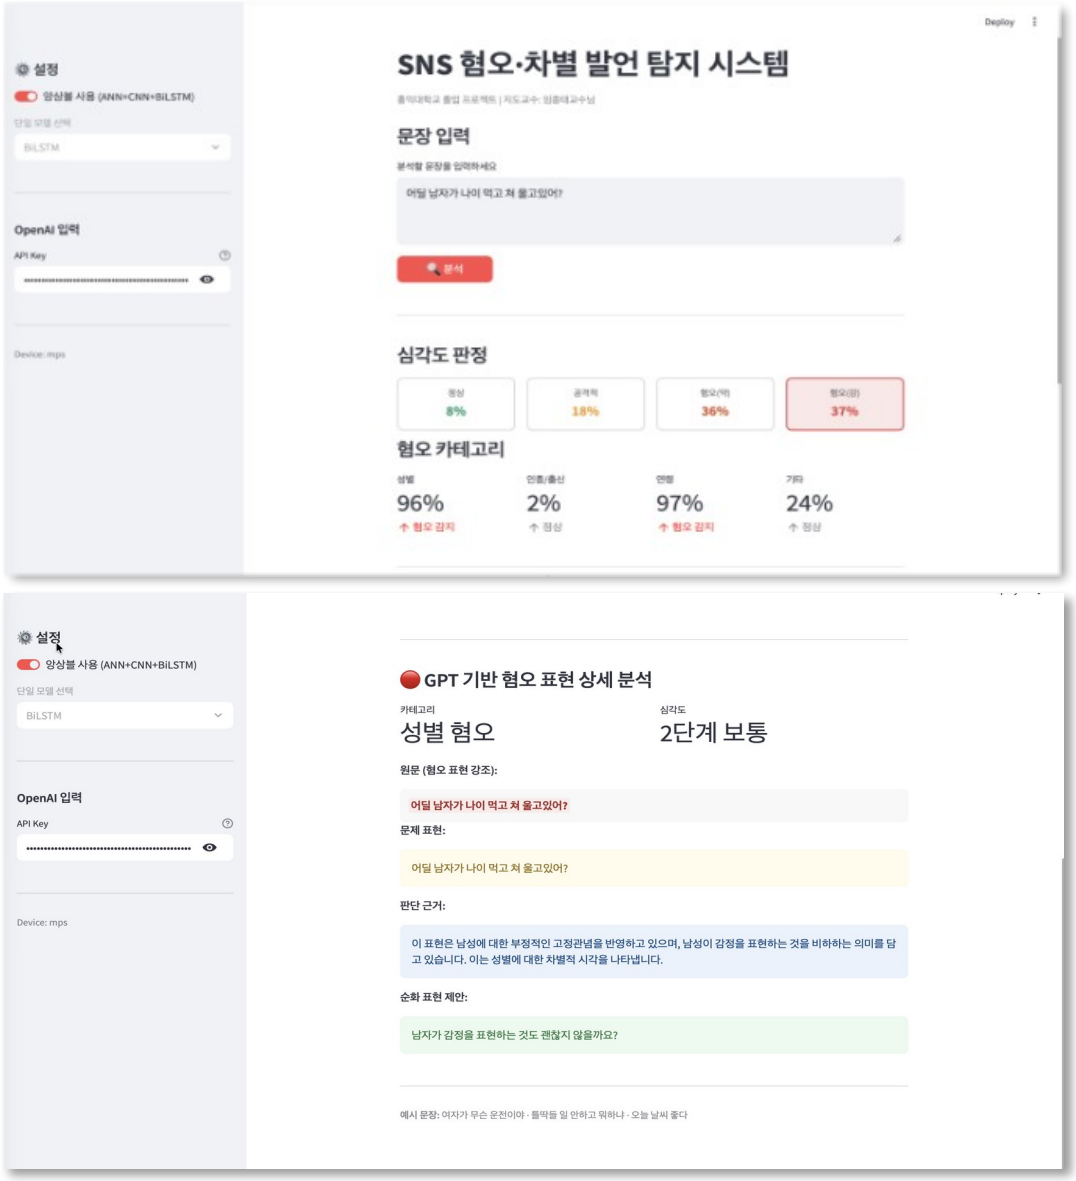
텍스트 입력 → 심각도 4 단계 + 카테고리 4 종 동시 출력

3 **OPEN API 연동**

혐오 표현 위치를 강조 + 순화된 대체 표현 제안

4 **모델 선택**

앙상블 / 단일 모델 (ANN·CNN·RNN) 선택 가능



출처 · Streamlit / OPEN API

LIMITATIONS & CONCLUSION

한계점과 결론

한계 (Limitations)

- 데이터 불균형 : 연령 (1%)· 성별 (2%) 혐오는 학습 데이터 부족으로 성능 한계
- L1_hate(약한 혐오) 는 경계가 모호해 모든 모델이 어려워함
- 향후 : 소수 클래스 데이터 증강 , 다양한 출처 추가 , 사전학습 모델 본격 도입

결론 (Conclusion)

1. ANN·CNN·RNN 직접 구현 · 비교 → BiLSTM 최우수
2. Weighted 앙상블로 일관된 성능 개선
3. KLUE-RoBERTa 와 비교로 모델 위치 확인
4. Streamlit 웹 시스템으로 실제 동작까지 구현

혐오 표현 탐지라는 사회적으로 의미 있는 문제에 수업에서 배운 내용을 끝까지 적용해본 프로젝트

감사합니다 .

참고문헌 · K-HATERS (EMNLP 2023) / KLUE (2021) / TextCNN — Kim (EMNLP 2014) / Streamlit · OPEN API