홍익대학교 IT 시스템종합설계 프로젝트

지도교수: 임종태 교수님
제출자: 산업데이터공학과 C221087 이승훈

데이터	인공지능 관련 사이트에서 다운로드한 데이터	본인이 직접 수집 및 전처리
문제	인공지능 관련 사이트에서의 문제	본인이 생각한 새로운 문제
Neural Network	ANN,CNN,RNN 수업 시간의 내용	ANN,CNN,RNN 수업 시간의 내용에 추가된 방법

SNS 혐오·차별 발언 자동 탐지 및 등급 분류 시스템

ANN · CNN · RNN 기반 멀티태스크 분류 모델의 비교 연구

소속: 홍익대학교 산업데이터공학과
학번-이름: C221087-이승훈
제출일: 2026 년 6 월 9 일

1. 서론

1.1 연구 배경

온라인 커뮤니티와 SNS 의 사용이 일상화되면서, 그 공간에서 오가는 혐오·차별 표현도 함께 늘어나고 있다. 온라인 플랫폼에서 차별 발언은 빠르게 증가하고 있으며, 그 전파 속도가 매우 빨라 사회적 갈등을 심화시키는 요인이 되고 있다. 특정 성별이나 연령, 출신 지역을 겨냥한 혐오 표현은 단순히 불쾌감을 주는 것을 넘어 실제 피해로 이어지기도 한다. 문제는 이런 표현이 매 순간 엄청난 양으로 쏟아진다는 점이다. 사람이 일일이 확인하고 걸러내는 것은 현실적으로 불가능하기 때문에, 객관적이고 일관된 기준으로 작동하는 딥러닝 기반 자동 탐지 기술의 필요성이 커지고 있다.

기존의 혐오 표현 탐지 연구들은 대부분 “혐오인가, 아닌가”를 가르는 이진 분류에 집중해 왔다. 하지만 실제 콘텐츠 관리 현장에서는 그것만으로는 부족하다. 어떤 종류의 혐오인지, 그리고 얼마나 심각한지에 따라 대응 방식이 완전히 달라지기 때문이다.

1.2 연구 목표

본 프로젝트의 목표는 하나의 문장을 입력받아 두 가지를 동시에 판별하는 시스템을 만드는 것이다. 첫째는 혐오의 종류, 즉 성별·인종/출신·연령·기타 중 어떤 카테고리에 해당하는지이고, 둘째는 혐오의 강도, 즉 정상·공격적·약한 혐오·강한 혐오의 4 단계 중 어디에 속하는지이다. 예를 들어 “여자가 무슨 운전이야”라는 문장이 입력되면, 시스템은 이를 성별 혐오로 분류하면서 동시에 강한 혐오 등급으로 판정한다.

이를 위해 수업에서 배운 세 가지 신경망 구조인 ANN, CNN, RNN 을 직접 구현하여 성능을 비교하고, 여기에 세 모델을 결합하는 앙상블 기법을 추가로 적용했다. 마지막으로 최근 자연어처리의 표준으로 자리잡은 사전학습 언어모델과도 비교하여, 직접 구현한 모델이 어느 수준에 있는지를 확인했다.

2. 데이터셋

2.1 K-HATERS 데이터셋

본 연구에서는 K-HATERS 데이터셋을 사용했다. 이 데이터셋은 한국어 뉴스 댓글을 기반으로 구축된 혐오 표현 코퍼스로, 총 192,158 건의 문장으로 이루어져 있다. 가장 큰 장점은 사람이 직접 라벨링한 고품질 데이터라는 점, 그리고 심각도와 타깃 카테고리를 모두 제공한다는 점이다.

심각도는 정상(normal), 공격적(offensive), 약한 혐오(L1_hate), 강한 혐오(L2_hate)의 4 단계로 나뉜다. 각 등급의 비율과 특징은 다음과 같다.

심각도	비율	특징
정상 (normal)	27.1%	일반적인 일상 대화·정보성 댓글
공격적 (offensive)	31.2%	비속어 포함 또는 무례한 표현
약한 혐오 (L1_hate)	11.3%	특정 집단에 대한 우회적 차별 표현
강한 혐오 (L2_hate)	30.4%	노골적인 혐오·폭력적 발언

타깃 카테고리는 성별, 연령, 지역, 종교, 정치, 개인, 직업, 장애 등으로 세분화되어 있으며, 한 문장에 여러 카테고리가 동시에 부여될 수 있다.

2.2 데이터 선택 과정

프로젝트 초반에는 K-HATERS 외에도 K-MHaS(109,692 건), UnSmile(18,742 건) 등 다른 한국어 혐오 데이터셋을 함께 활용하는 방안을 검토했다. 특히 데이터를 더 많이 확보하기 위해, K-HATERS 로 심각도 분류기를 학습시킨 뒤 그 분류기로 K-MHaS 에 심각도 라벨을 자동으로 붙이는 방법을 고려했다.

그러나 이 방식에는 논리적 문제가 있었다. 자동으로 붙인 라벨은 분류기의 정확도(F1 기준 약 0.65~0.80)만큼만 신뢰할 수 있는데, 부정확한 라벨이 섞인 데이터로 다시 모델을 학습시키면 그 오류가 그대로 전파된다. 시험 공부를 하는데 답지의 20~30%가 틀려 있는 것과 같은 상황이다. 이 문제를 인지한 후, 학습에는 사람이 직접 라벨링한 K-HATERS 만 사용하기로 결정했다.

또한 K-MHaS 와 UnSmile 은 심각도 라벨이 없어, 우리 시스템의 핵심 기능인 심각도 분류를 평가하는 데 사용할 수 없다는 한계도 있었다. 결과적으로 심각도와 카테고리를 모두 제공하는 K-HATERS 가 본 시스템에 가장 적합한 데이터셋이었다.

2.3 전처리

원본 데이터에는 개인정보 보호를 위한 익명화 토큰(#@이름# 형태), URL, 사용자 멘션(@), HTML 태그 등 분석에 불필요한 요소가 섞여 있었다. 전처리 과정에서는 먼저 유니코드 NFC 정규화를 수행하여 한글 자모가 결합된 형태로 통일했고, 이어 익명화 토큰·URL·멘션·HTML 태그를 정규표현식으로 제거했다. 또한 한글 자모의 과도한 반복(예: ㅋㅋㅋㅋㅋ)은 두 글자로 축소했으며, 연속된 공백을 정규화하고 2 글자 미만의 지나치게 짧은 텍스트는 분석에서 제외했다

실제 전처리 예시는 다음과 같다.

```
[BEFORE]
ㅋㅋㅋㅋㅋ #@닉네임# 진짜 https://t.co/a 짜증나 <br> @user
```

```
[AFTER]
ㅋㅋ 진짜 짜증나
```

2.4 멀티태스크 라벨 구성

라벨 구성은 이 프로젝트에서 가장 많이 고민한 부분이다. 처음에는 카테고리 4 종과 심각도 3 단계를 곱한 12 개의 클래스로 한 번에 분류하는 방식(단일 라벨)을 설계했다. 그러나 이 방식은 한 문장에 여러 혐오가 동시에 존재하는 경우를 처리할 수 없다는 치명적인 문제가 있었다. “여자 노인이 운전하면 사고 난다”와 같은 문장은 성별 혐오와 연령 혐오가 함께 들어 있는데, 단일 라벨로는 둘 중 하나만 선택해야 하므로 정보 손실이 발생한다.

이 문제를 해결하기 위해 출력 구조를 멀티태스크 방식으로 재설계했다. 카테고리는 9 종을 4 종(성별 / 인종·출신 / 연령 / 기타)으로 통합한 뒤, 각 카테고리마다 독립적으로 해당 여부를 판단하는 이진 분류로 구성했다. 이렇게 하면 한 문장이 여러 카테고리에 동시에 속할 수 있다. 심각도는 별도의 4 단계 분류로 분리했다. 이 설계 변경은 이후 성능을 크게 끌어올리는 결정적인 역할을 했다.

3. 모델 설계 및 비교 실험

3.1 공통 구조

세 모델의 공정한 비교를 위해, 입력 표현과 출력 구조는 동일하게 고정하고 중간의 인코더 부분만 ANN, CNN, RNN 으로 바꾸었다. 전체 구조는 다음과 같다.

```
                입력 텍스트
                    ↓
   KLUE-BERT 사전학습 임베딩 (768 차원 → 256 차원)
                    ↓
   [ ANN / TextCNN / BiLSTM ]  ← 비교 대상 인코더
                    ↓
멀티태스크 출력: 카테고리 4 개(sigmoid) + 심각도 1 개(softmax)
```

단어를 벡터로 변환하는 임베딩 층은 KLUE-BERT 의 사전학습된 임베딩을 가져와 사용했다. 초기에는 임베딩을 무작위 초기화 상태에서 처음부터 학습시키는 방안도 시도했으나, 19 만 건의 데이터만으로는 단어의 의미를 충분히 학습하기에 부족했다. 사전학습 임베딩을 활용하면서 학습 과정에서 함께 미세조정하는 방식이 훨씬 안정적이고 성능도 좋았다.

3.2 세 가지 모델 구조

ANN(Artificial Neural Network)은 가장 기본적인 구조다. 임베딩된 단어 벡터들을 평균 풀링과 최대 풀링으로 요약한 뒤 다층 퍼셉트론을 통과시킨다. 단어 순서를 활용하지 않는 한계가 있지만

구조가 단순하고 학습이 빠르다.

TextCNN(Text Convolutional Neural Network)은 문장을 1차원 신호로 보고 크기 2, 3, 4, 5의 합성곱 필터로 다양한 길이의 n-gram 패턴을 포착한다. 각 필터 출력에 배치 정규화를 적용해 학습을 안정화했으며, 지역적 단어 조합 패턴을 잡아내는 데 강점이 있다.

BiLSTM(Bidirectional LSTM)은 RNN의 여러 모델 중 한 종류로 양방향 LSTM으로 문장을 앞뒤로 동시에 읽어 문맥을 파악한다. 여기에 Self-Attention을 추가해 중요한 단어에 더 집중하도록 했다. 단어 순서와 장거리 의존 관계를 반영할 수 있어 세 모델 중 가장 정교한 구조다.

3.3 학습 설정

데이터는 학습 80%, 검증 10%, 평가 10%로 나누었으며, 심각도 분포를 기준으로 층화추출하여 각 세트의 분포가 균일하도록 했다. 손실 함수는 카테고리에 대해 클래스 불균형을 보정하는 가중치를 적용한 BCEWithLogitsLoss를, 심각도에 대해서는 클래스 가중치와 label smoothing을 적용한 CrossEntropyLoss를 사용했다. 최적화에는 AdamW를 사용하되, 사전학습 임베딩은 작은 학습률(1e-5)로 천천히, 새로 추가한 층은 큰 학습률(1e-4)로 학습하도록 차등을 두었다. 학습 환경은 Apple Silicon 맥북이었으며, 학습 속도와 일부 연산 호환성 문제로 시행착오가 있었으나 배치 크기와 데이터 로더 설정을 조정하여 안정적으로 학습을 완료했다.

3.4 비교 실험 결과

세 모델의 평가셋 성능은 다음과 같다.

모델	성별	인종	연령	기타	카테고리 평균	심각도	종합 F1
ANN	0.512	0.583	0.337	0.805	0.559	0.563	0.561
TextCNN	0.446	0.555	0.263	0.804	0.517	0.566	0.541
BiLSTM	0.541	0.591	0.374	0.804	0.577	0.565	0.571

종합 성능은 BiLSTM(0.571) > ANN(0.561) > TextCNN(0.541) 순으로 나타났다. 양방향 LSTM과 Attention을 결합한 BiLSTM이 가장 우수했는데, 이는 단어의 순서와 문맥을 반영하는 시퀀스 모델이 한국어 혐오 표현의 미묘한 맥락을 파악하는 데 유리하기 때문으로 분석된다. 반면 단어 순서를 무시하는 ANN이나 좁은 구간의 패턴만 보는 TextCNN은 상대적으로 불리했다.

카테고리별로 보면 모든 모델이 공통된 경향을 보였다. '기타' 카테고리는 0.80 내외로 잘 분류한 반면, '연령'은 0.26~0.37로 매우 낮았다. 이는 모델의 성능 문제라기보다, 연령 혐오 데이터가 전체의 1%에 불과한 데이터 불균형 때문이다.

4. 성능 개선 — 앙상블

세 모델을 각각 비교하는 데서 그치지 않고, 이들을 결합하여 성능을 더 끌어올리는 방안을 적용했다. 방법은 Weighted Voting 으로, 세 모델이 출력한 예측 확률을 검증셋 성능을 기준으로 가중 평균하는 방식이다. 더 좋은 성능을 보인 모델에 더 큰 영향력을 부여한다. 산출된 가중치는 ANN 0.334, TextCNN 0.331, BiLSTM 0.336 이었다.

모델	종합 F1
BiLSTM (단일 최고)	0.571
Weighted Ensemble	0.582

앙상블의 종합 F1 은 0.582 로, 단일 최고 모델인 BiLSTM(0.571)보다 0.011 향상되었다. 향상폭 자체는 크지 않지만, 주목할 점은 네 개 카테고리와 심각도까지 모든 평가 항목에서 빠짐없이 성능이 올랐다는 것이다. 이는 세 모델이 각기 다른 부분에서 강점을 가지며, 이들이 서로의 약점을 보완하고 있음을 보여준다. 특히 분류가 가장 어려웠던 약한 혐오(L1_hate) 등급에서도 개선이 관찰되었다.

5. 사전학습 모델과의 비교

본 프로젝트의 핵심은 수업에서 배운 ANN, CNN, RNN 을 직접 구현하고 비교하는 것이다. 다만 직접 구현한 모델이 현재 자연어처리 분야의 표준 기법과 비교했을 때 어느 수준에 있는지를 확인하는 것도 의미가 있다고 판단했다. 이를 위해 KLUE-RoBERTa 라는 한국어 사전학습 언어모델을 같은 과제에 적용하여 참고용 비교 실험을 진행했다.

모델	종합 F1
ANN / TextCNN / BiLSTM	0.541 ~ 0.571
Weighted Ensemble	0.582
KLUE-RoBERTa	0.620

KLUE-RoBERTa 가 종합 F1 0.620 으로 가장 높은 성능을 보였다. 앙상블 대비 약 0.038, 비율로는 4%포인트 정도 높은 수치다. 사전학습 모델은 방대한 한국어 텍스트로 미리 언어를 학습한 상태에서 시작하기 때문에, 우리 모델보다 한국어의 깊은 의미와 맥락을 더 잘 파악한다. 다만 그 격차가 압도적이지는 않다는 점이 오히려 의미가 있다. 임베딩을 제외하고 본체를 직접 구현한 모델과 앙상블만으로도, 최신 사전학습 모델에 크게 뒤지지 않는 성능에 도달했기 때문이다.

6. 시스템 구현

학습한 모델을 실제로 사용할 수 있도록 Streamlit 기반의 웹 시스템으로 구현했다. 브라우저에서 바로 동작하는 실시간 탐지 인터페이스로, 주요 기능은 다음 네 가지다.

첫째, 사용자가 문장을 입력하면 즉시 심각도 4 단계와 카테고리 4 종에 대한 판별 결과를 확률과 함께 출력한다.

둘째, 사이드바에서 앙상블과 개별 모델(ANN, CNN, RNN) 중 어떤 것으로 예측할지 선택할 수 있다.

셋째, OpenAI API 를 연동해 혐오 표현의 위치를 강조하고 순화된 대체 표현을 제안한다.

넷째, 모든 결과를 시각적으로 표시한다.

6.1 OpenAI API 의 역할 분담

여기에서 가장 핵심적인 부분은 OpenAI API(GPT)를 연동한 것이다. 다만 GPT 를 “이 문장이 혐오인가”를 판별하는데 사용하지는 않았다. 그 판별은 이미 우리가 직접 학습시킨 ANN/CNN/RNN 모델이 담당하기 때문이다. 대신 우리 모델이 하기 어려운 두 가지 작업, 즉 혐오 표현의 정확한 위치 추출과 순화 표현 생성을 GPT 에 맡겼다. 우리 모델은 문장 전체를 보고 “성별 혐오, 강한 등급”이라고 분류할 수는 있지만, 문장 안에서 정확히 어느 단어나 구절이 문제인지 짚어내거나 그것을 자연스러운 대안 표현으로 바꾸는 일은 하지 못한다. 이 부분을 생성형 언어모델로 보완하여, 분류는 우리 모델이, 위치 추출과 순화는 GPT 가 담당하도록 역할을 분담한 것이다.

6.2 프롬프트 설계

GPT 에서 원하는 결과를 안정적으로 얻기 위해서는 프롬프트를 어떻게 구성하느냐가 중요했다. 실제 사용한 프롬프트는 다음과 같다.

```
다음 문장에서 혐오·차별 표현을 분석해줘.

문장: "{입력 문장}"

아래 형식으로만 답변:
HATE_PHRASES: (혐오 표현을 쉼표로 구분, 없으면 NONE)
SOFTENED: (순화된 표현)
REASON: (왜 혐오 표현인지 한 줄 설명, 없으면 NONE)
```

이 프롬프트는 세 가지 원칙을 가지고 직접 설계했다.

첫째, 출력 형식을 고정했다. HATE_PHRASES, SOFTENED, REASON 이라는 정해진 키를 각 줄 앞에 붙이도록 강제했다. GPT 가 자유롭게 답하면 매번 문장 구조가 달라져서 프로그램이 결과를 자동으로 처리하기 어렵다. 키를 고정하면 프로그램이 각 줄의 앞부분만 보고 어떤 정보인지 정확히 구분해 추출할 수 있다. 실제 구현에서는 GPT 의 응답을 줄 단위로 나눈 뒤, HATE_PHRASES 로 시작하는 줄에서 혐오 표현 목록을, SOFTENED 로 시작하는 줄에서 순화 표현을 뽑아낸다.

둘째, 혐오 표현이 없는 경우를 명시적으로 처리했다. "없으면 NONE"이라는 조건을 넣어, 정상적인 문장이 입력되었을 때 GPT 가 억지로 혐오 표현을 만들어내지 않도록 했다. 프로그램은 NONE 이라는 응답을 받으면 강조 표시를 하지 않고 "혐오 표현이 발견되지 않았다"고 안내한다. 이는 정상 문장에 대한 오탐(false positive)을 줄이기 위한 장치다.

셋째, 판단 근거를 함께 요청했다. 단순히 순화 표현만 제안하는 것이 아니라 "왜 이것이 혐오 표현인지"를 한 줄로 설명하도록 했다. 이는 시스템이 내린 판단을 사용자가 납득할 수 있도록 만드는 설명 가능성 측면에서 추가한 것으로, 단순한 탐지 도구를 넘어 사용자가 표현을 스스로 점검하고 개선하도록 돕는 역할을 한다.

6.3 결과 처리 및 화면 구성

GPT 의 응답을 받은 뒤, HATE_PHRASES 로 추출된 표현들을 원문에서 찾아 빨간색 배경으로 강조 표시한다. SOFTENED 로 받은 순화 문장은 별도 영역에 초록색으로 표시하여, 사용자가 원문과 대안을 한눈에 비교할 수 있게 했다. 예를 들어 "여자가 무슨 운전이야"라는 문장을 입력하면, 시스템은 우리 모델로 성별 혐오·강한 등급임을 판별하고, GPT 를 통해 혐오 부분을 빨갛게 강조한 뒤 "운전 실력은 성별과 무관합니다"와 같은 순화 표현을 함께 제시한다.

단순히 모델의 성능 수치를 비교하는 데서 끝내지 않고, 탐지부터 표현 순화까지 이어지는 실제 동작하는 시스템을 완성했다는 점이 이 프로젝트에서 가장 공들인 부분이다.

7. 한계 및 향후 과제

가장 큰 한계는 데이터 불균형이다. 연령 혐오(전체의 1%)와 성별 혐오(2%)는 학습 데이터 자체가 부족해, 어떤 모델로도 높은 성능을 내기 어려웠다. 이는 특정 모델의 문제가 아니라 데이터의 구조적 문제이며, 모든 실험에서 공통적으로 관찰되었다. 또한 약한 혐오(L1_hate) 등급은 공격적 표현이나 강한 혐오와의 경계가 모호해, 사람이 보기에도 판단이 갈리는 경우가 많았고 모델도 이를 어려워했다. 마지막으로, 심각도 라벨이 K-HATERS 에만 존재하기 때문에 다른 데이터셋을 활용한 일반화 성능 검증에 제약이 있었다.

향후 과제로는 소수 클래스에 대한 데이터 증강으로 불균형을 완화하는 방안이 있다. 또한 여러 출처의 한국어 혐오 데이터를 추가로 확보하여 학습 데이터를 늘리고, 사전학습 모델을 본격적으로 도입한다면 실제 서비스 수준의 성능에 도달할 수 있을 것으로 기대한다.

8. 결론

본 프로젝트는 한국어 SNS 혐오·차별 발언을 자동으로 탐지하고, 그 종류와 심각도를 동시에 분류하는 시스템을 구축했다. 수업에서 배운 ANN, CNN, RNN 세 가지 신경망을 직접 구현하여 비교한 결과 BiLSTM 이 가장 우수했으며(종합 F1 0.571), 이를 결합한 Weighted Voting 앙상블로 성능을 0.582 까지 개선했다. 또한 최신 사전학습 모델인 KLUE-RoBERTa(0.620)와 비교하여 직접 구현한 모델의 위치를 객관적으로 확인했다.

이 프로젝트의 의의는 단순한 모델 비교를 넘어, 모델 비교에서 앙상블, 사전학습 모델 비교, 그리고 실제 동작하는 시스템 구현으로 이어지는 점진적인 발전 과정을 하나의 파이프라인으로 완성했다는 데 있다. 각 단계에서 마주친 한계를 분석하고, 그것이 다음 단계의 동기가 되도록 프로젝트를 진행했다. 혐오 표현 탐지라는 사회적으로 의미 있는 문제에, 수업에서 배운 내용을 끝까지 적용해본 경험이었다.

참고문헌

[1] Park, S. et al., “K-HATERS: A Hate Speech Detection Corpus in Korean with Target-Specific Ratings”, Findings of EMNLP 2023.

[2] Park, S. et al., “KLUE: Korean Language Understanding Evaluation”, NeurIPS 2021 Datasets and Benchmarks.

[3] Kim, Y., “Convolutional Neural Networks for Sentence Classification”, EMNLP 2014.

[4] Streamlit, https://docs.streamlit.io
[5] OpenAI API 공식 , https://platform.openai.com